



Я ✨ Практикум

Проект Predict the Cure

Выполнила команда № 15 Дрим-Тим:

*Полякова Полина Викторовна
Прусова Юлия Витальевна
Костенко Светлана Николаевна
Шитова Наталья Владимировна
Цветкова Арина Владимировна*

МАЙ 2026



ПОДГОТОВКА ДАННЫХ

2



ПОКАЗАТЕЛИ

1. Заполнение пропусков данных:
медианное значение
2. **Удаление** 18-ти «**константных**» признаков
3. **Удаление** 6-ти признаков – «**дубликатов**»



210
признаков

vs

186
признаков

Использование для
целей обучения всех
признаков без их
парообразования

Корреляции
«слабые» но все
признаки значимы



НАБЛЮДЕНИЯ

1. **Удаление наблюдений – выбросов:**

15 ближайших соседей по «входящим» признакам
+
исключение на основе распределения z-score,
используя правило 3 сигм:
 $\text{порог} = \text{mean_z} + 3 \times \text{std_z}$

- 9 для показателя IC50;
- 12 для показателя CC50;
- 15 для показателя SI

2. Берем «**общие**» наблюдения

3. **Исключаем** «**экстремальные**» значения для **SI**

710
элементов

vs

IC: 715
CC: 715
SI: 679
элементов



ОБУЧЕНИЕ

3

$$score = \frac{RMSE^{IC} + RMSE^{CC} + RMSE^{SI}}{3}$$

1) Три модели, которые не чувствительны к мультиколлинеарности и не требуют масштабирования признаков

2) Для каждой модели предусмотрен подбор нескольких гиперпараметров:

- LightGBMRegressor: осторожная, хорошо регуляризованная, для сложных данных с риском переобучения
- RandomForestRegressor : классическая, сбалансированная, надежная
- ExtraTreesRegressor: агрессивная, максимально случайная, для данных с сильным шумом и сложными паттернами

МОДЕЛЬ TARGET	IC50	CC50	SI
LightGBMRegressor	276.8	439.7	15.1
RandomForestRegressor	274.5	446.4	15
ExtraTreesRegressor	273.6 ✓	432.1 ✓	14.9 ✓
Метрика RMSE лучшей модели на валидационной выборке	384.6	432.8	19.1

Усредненные значения на 5 фолдах кросс-валидации

$$score = 278.8$$



РЕЗУЛЬТАТЫ

4

По состоянию
на 25.05.2025

≡ kaggle



ChemAI: Predict the Cure

< Leaderboard Rules Team Submis >

79 Команда 15 Дрим Тим

294.63303

По состоянию
на 29.05.2025

≡ kaggle



ChemAI: Predict the Cure

< Leaderboard Rules Team Submis >

68 Команда_15_Дрим Тим

286.70562

- 7.9 (или 2.8%)

Усредненное RMSE по результатам обучения трех моделей **278.8**, а показатель на kaggle **на тестовой выборке 286.7**:

- качество предсказаний - в целом хорошее
- обобщающая способность - отличная (разрыв всего 2.8%)
- стабильность моделей – высокая

Лучшие модели готовы к использованию, - усредненный RMSE на тестовых данных - это ожидаемый уровень ошибки на новых данных